

SPIS TREŚCI

1	Wstęp	3
1.1	Cel pracy	3
1.2	Zakres pracy	3
1.3	Problem badawczy	4
1.4	Struktura pracy	5
2	Podstawy teoretyczne	7
2.1	Poker jako gra z niepełną informacją	7
2.2	Texas Hold'em	7
2.3	Ranking układów pokerowych	7
2.4	Ultimate Texas Hold'em	8
2.4.1	Charakterystyka gry	8
2.4.2	Różnice względem klasycznego Texas Hold'em	8
2.4.3	Przebieg rozdania	9
2.4.4	Zakłady i decyzje gracza	9
2.4.5	Rozstrzygnięcie rozdania	9
2.4.6	Zakłady poboczne	10
2.4.7	Tabele wypłat	10
2.5	Wartość oczekiwana, house edge i strategia bazowa	11
2.6	Uczenie przez wzmacnianie	12
3	Projekt i implementacja środowiska Ultimate Texas Hold'em	15
3.1	Założenia projektowe środowiska	15
3.2	Architektura rozwiązania	16
3.2.1	Przepływ danych podczas wykonania akcji	18
3.3	Model kart i sterowanie talią	19
3.3.1	Reprezentacja karty	19
3.3.2	Standardowa talia	19
3.3.3	Abstrakcja źródła kart	20
3.3.4	Deterministyczna talia testowa	20
3.3.5	Powtarzalność losowych rozdań	21
3.4	Ocena układów pokerowych	21

3.4.1	Reprezentacja wartości ręki	22
3.4.2	Ocena układu pięciokartowego	22
3.4.3	Obsługa niskiego strita z asem	23
3.4.4	Wybór najlepszej ręki	24
3.5	Stan wewnętrzny i obserwacja agenta	24
3.5.1	Pełny stan rozdania	25
3.5.2	Obserwacja agenta	26
3.5.3	Projekcja stanu na obserwację	27
3.5.4	Ochrona przed wyciekiem informacji	28

1. Wstęp

Gry karciane stanowią interesujący obszar zastosowań metod sztucznej inteligencji, ponieważ łączą element losowości, niepełnej informacji oraz sekwencyjnego podejmowania decyzji. W przeciwieństwie do wielu klasycznych problemów uczenia maszynowego, w których model uczy się na podstawie gotowego zbioru danych, w grach agent musi samodzielnie podejmować decyzje, obserwować ich konsekwencje i stopniowo poprawiać swoją strategię.

Szczególnie interesującym przypadkiem są gry pokerowe, w których wynik pojedynczego rozdania zależy nie tylko od jakości posiadanych kart, ale również od decyzji podejmowanych w kolejnych etapach gry. Ultimate Texas Hold'em jest kasynową odmianą pokera opartą na zasadach Texas Hold'em, w której gracz rywalizuje z krupierem, a nie z innymi graczami. Gra ta posiada ograniczoną liczbę możliwych akcji, jasno określone reguły wypłat oraz sekwencyjny przebieg rozdania, co czyni ją odpowiednim środowiskiem do modelowania jako problem uczenia przez wzmacnianie.

Uczenie przez wzmacnianie (ang. *reinforcement learning*, RL) pozwala analizować sytuacje, w których agent uczy się strategii poprzez interakcję ze środowiskiem. W przypadku Ultimate Texas Hold'em środowiskiem może być symulator gry, stanem aktualna sytuacja w rozdaniu, akcją decyzja gracza, natomiast nagrodą końcowy wynik finansowy rozdania. Takie podejście umożliwia badanie, w jaki sposób różne reprezentacje stanu oraz różne definicje funkcji nagrody wpływają na jakość wyuczonej strategii.

1.1. Cel pracy

Głównym celem pracy jest porównanie wybranych metod uczenia przez wzmacnianie w zadaniu uczenia strategii gry w Ultimate Texas Hold'em. Szczególny nacisk położony zostanie na analizę wpływu reprezentacji stanu oraz funkcji nagrody na jakość strategii uzyskiwanej przez agenta.

Celem praktycznym pracy jest implementacja środowiska symulującego rozgrywkę w Ultimate Texas Hold'em oraz przygotowanie agentów podejmujących decyzje w kolejnych etapach rozdania. Uzyskane strategie zostaną porównane ze strategiami bazowymi, takimi jak agent losowy oraz prosty agent regułowy.

1.2. Zakres pracy

Zakres pracy obejmuje zaprojektowanie i implementację uproszczonego środowiska gry Ultimate Texas Hold'em, w którym uwzględnione zostaną podstawowe elementy rozgrywki: karty gracza i krupiera, karty wspólne, obowiązkowe zakłady Ante i Blind oraz

decyzyjny zakład Play. W podstawowej wersji środowiska pominięte zostaną zakłady poboczne, takie jak Trips oraz Progressive, ponieważ nie są one bezpośrednio związane z głównym procesem decyzyjnym agenta.

W ramach pracy zostaną przygotowane różne warianty reprezentacji stanu gry. Reprezentacja stanu może obejmować między innymi informacje o kartach gracza, kartach wspólnych, aktualnym etapie rozdania oraz dostępnych akcjach. Analizie podlegać będzie również sposób definiowania funkcji nagrody, w szczególności to, czy agent otrzymuje nagrodę wyłącznie na końcu rozdania, czy także dodatkowe informacje pośrednie wspierające proces uczenia.

Założenia niniejszej pracy są następujące:

1. Implementacja środowiska symulującego rozgrywkę w Ultimate Texas Hold'em zgodnie z podstawowymi zasadami gry.
2. Implementacja mechanizmu oceny układów pokerowych oraz rozstrzygania wyniku rozdania pomiędzy graczem a krupierem.
3. Przygotowanie agentów bazowych, w szczególności agenta losowego oraz prostego agenta regułowego.
4. Implementacja i porównanie wybranych metod uczenia przez wzmacnianie w zadaniu podejmowania decyzji w Ultimate Texas Hold'em.
5. Analiza wpływu różnych reprezentacji stanu na jakość wyuczonej strategii.
6. Analiza wpływu różnych funkcji nagrody na stabilność procesu uczenia oraz końcowy wynik agenta.
7. Ocena agentów z wykorzystaniem metryk takich jak średni wynik na rozdanie, wartość oczekiwana strategii oraz porównanie względem strategii bazowych.

1.3. Problem badawczy

Problem badawczy rozważany w pracy można sformułować następująco: w jaki sposób wybór reprezentacji stanu oraz funkcji nagrody wpływa na skuteczność metod uczenia przez wzmacnianie w grze Ultimate Texas Hold'em?

W pracy analizowane będzie, czy agent uczony metodami reinforcement learning jest w stanie uzyskać strategię lepszą od strategii losowej oraz prostych heurystyk. Ze względu na konstrukcję gier kasynowych celem nie jest wykazanie, że agent może trwale osiągnąć dodatnią wartość oczekiwaną przeciwko kasynu, lecz sprawdzenie, czy możliwe jest nauczenie strategii minimalizującej oczekiwaną stratę.

1.4. Struktura pracy

Praca składa się z kilku rozdziałów. W rozdziale pierwszym przedstawiono cel, zakres oraz problem badawczy pracy. Rozdział drugi zawiera podstawy teoretyczne dotyczące pokera, Texas Hold'em, Ultimate Texas Hold'em, wartości oczekiwanej, przewagi kasyna oraz uczenia przez wzmacnianie.

W kolejnych rozdziałach opisany zostanie projekt środowiska symulacyjnego, sposób reprezentacji stanu gry, funkcja nagrody oraz zastosowane metody uczenia przez wzmacnianie. Następnie przedstawione zostaną eksperymenty, uzyskane wyniki oraz analiza porównawcza agentów. Ostatni rozdział będzie zawierał podsumowanie pracy, wnioski oraz możliwe kierunki dalszego rozwoju.

2. Podstawy teoretyczne

2.1. Poker jako gra z niepełną informacją

Poker jest rodziną gier karcianych, w których wynik zależy zarówno od losowego rozdania kart, jak i od decyzji podejmowanych przez graczy. W przeciwieństwie do gier z pełną informacją, takich jak szachy, uczestnicy rozgrywki nie znają wszystkich elementów stanu gry. Ukryte pozostają przede wszystkim karty przeciwników, co sprawia, że decyzje podejmowane są w warunkach niepewności.

Z punktu widzenia sztucznej inteligencji poker jest interesującym problemem badawczym, ponieważ łączy losowość, niepełną informację, sekwencyjne podejmowanie decyzji oraz konieczność maksymalizacji wyniku w długim horyzoncie czasowym. W takim środowisku pojedyncza decyzja nie powinna być oceniana wyłącznie przez pryzmat wyniku jednego rozdania, lecz przez jej wpływ na oczekiwaną wartość strategii w wielu powtórzeniach gry.

2.2. Texas Hold'em

Texas Hold'em jest jedną z najpopularniejszych odmian pokera. Każdy gracz otrzymuje dwie zakryte karty własne (ang. *hole cards*), natomiast na stole stopniowo odkrywanych jest pięć kart wspólnych (ang. *community cards*). Gracz tworzy najlepszy możliwy układ pięciokartowy, wykorzystując dowolną kombinację swoich dwóch kart oraz pięciu kart wspólnych.

Rozgrywka w klasycznym Texas Hold'em składa się z kilku etapów: etapu przed flopem (ang. *preflop*), flopa (ang. *flop*), czyli odkrycia trzech pierwszych kart wspólnych, turna (ang. *turn*), czyli czwartej karty wspólnej, rivera (ang. *river*), czyli piątej i ostatniej karty wspólnej, oraz showdownu (ang. *showdown*), czyli końcowego porównania układów. W trakcie kolejnych rund licytacji gracze mogą podejmować decyzje takie jak czekanie (ang. *check*), postawienie zakładu (ang. *bet*), sprawdzenie zakładu przeciwnika (ang. *call*), podbicie (ang. *raise*) lub spasowanie (ang. *fold*). W odmianach no-limit możliwe jest również stosowanie różnych rozmiarów zakładów, co istotnie zwiększa przestrzeń możliwych strategii.

2.3. Ranking układów pokerowych

W Texas Hold'em oraz Ultimate Texas Hold'em wynik rozdania zależy od siły najlepszego układu pięciokartowego utworzonego z dostępnych kart. Układy pokerowe mają ustaloną hierarchię, która pozwala jednoznacznie porównać rękę gracza i krupiera

podczas showdownu. Przykładowy ranking układów od najsilniejszego do najslabszego przedstawiono w tabeli 2.1 [1].

Najsilniejszym układem jest poker królewski, natomiast najslabszym układem jest wysoka karta. W przypadku gdy dwóch uczestników rozdania posiada układ tej samej kategorii, o zwycięstwie decydują wartości kart wchodzących w skład układu oraz karty dodatkowe, określane jako kickery.

Tabela 2.1. Ranking układów pokerowych od najsilniejszego do najslabszego

Układ	Opis
Poker królewski	A, K, Q, J, 10 w tym samym kolorze
Poker	Pięć kolejnych kart w tym samym kolorze
Kareta	Cztery karty tej samej wartości
Full	Trójka oraz para
Kolor	Pięć kart w tym samym kolorze
Strit	Pięć kolejnych kart
Trójka	Trzy karty tej samej wartości
Dwie pary	Dwa różne układy par
Para	Dwie karty tej samej wartości
Wysoka karta	Brak silniejszego układu

2.4. Ultimate Texas Hold'em

2.4.1. Charakterystyka gry

Ultimate Texas Hold'em jest kasynową odmianą pokera opartą na zasadach Texas Hold'em. W przeciwieństwie do klasycznej odmiany wieloosobowej gracz nie rywalizuje z innymi graczami, lecz z krupierem reprezentującym kasyno. Zarówno gracz, jak i krupier otrzymują po dwie karty własne, a następnie korzystają z pięciu kart wspólnych w celu utworzenia najlepszego możliwego układu pięciokartowego [1], [2].

2.4.2. Różnice względem klasycznego Texas Hold'em

Najważniejsza różnica względem klasycznego Texas Hold'em polega na tym, że w Ultimate Texas Hold'em gracz podejmuje decyzje przeciwko kasynu, a nie przeciwko innym graczom. Nie występuje więc klasyczna rywalizacja między wieloma uczestnikami stołu, nie ma konieczności blefowania przeciwników ani reagowania na ich indywidualne style gry.

Istotną cechą Ultimate Texas Hold'em jest również ograniczona liczba momentów decyzyjnych. Gracz może wykonać zakład Play (ang. *Play bet*) tylko raz w trakcie rozdania: przed flopem, po flopie albo po odkryciu wszystkich kart wspólnych. Im wcześniej gracz zdecyduje się na zagranie agresywne, tym większy zakład może postawić, ale decyzja jest wtedy podejmowana przy mniejszej liczbie informacji [1], [3].

Tabela 2.2. Porównanie Texas Hold'em i Ultimate Texas Hold'em

Cecha	Texas Hold'em	Ultimate Texas Hold'em
Przeciwnik	inni gracze	krupier / kasyno
Liczba graczy	wielu	jeden gracz przeciwko dealerowi
Zakłady	zmienne	ustalone mnożniki Ante
Blefowanie	istotne	brak klasycznego blefowania
Liczba decyzji	duża	ograniczona

2.4.3. Przebieg rozdania

Rozdanie rozpoczyna się od postawienia przez gracza obowiązkowych zakładów Ante (ang. *Ante bet*) oraz Blind (ang. *Blind bet*). Zakłady te mają zwykle taką samą wartość. Opcjonalnie gracz może również postawić zakład poboczny (ang. *side bet*), na przykład Trips, który jest rozliczany niezależnie od wyniku pojedynku z krupierem [1].

Po wniesieniu zakładów gracz oraz krupier otrzymują po dwie zakryte karty własne. Następnie gracz podejmuje pierwszą decyzję. Może zaczekać albo wykonać zakład Play w wysokości trzykrotności lub czterokrotności zakładu Ante.

Jeżeli gracz nie wykona zakładu Play przed flopem, odkrywane są trzy pierwsze karty wspólne, czyli flop. Na tym etapie gracz może ponownie zaczekać albo wykonać zakład Play w wysokości dwukrotności Ante. Jeżeli również po flopie gracz zdecyduje się zaczekać, odkrywane są dwie ostatnie karty wspólne, czyli turn oraz river. Wtedy gracz musi wybrać pomiędzy spasowaniem a wykonaniem zakładu Play w wysokości jednokrotności Ante [1], [3].

2.4.4. Zakłady i decyzje gracza

W podstawowym modelu gry występują trzy główne rodzaje zakładów: Ante, Blind oraz Play. Zakłady Ante i Blind są obowiązkowe i stawiane przed rozpoczęciem rozdania. Zakład Play jest natomiast bezpośrednio związany z decyzją gracza i może zostać wykonany tylko raz w trakcie rozdania.

Z punktu widzenia modelowania problemu jako środowiska uczenia przez wzmocnienie najważniejszy jest zakład Play, ponieważ jego wysokość i moment wykonania wynikają z decyzji agenta. Ante i Blind można traktować jako początkowy koszt udziału w rozdaniu, natomiast Play odzwierciedla wybór strategii w aktualnym stanie gry.

Dostępne decyzje gracza w poszczególnych etapach rozdania przedstawiono w tabeli 2.3.

2.4.5. Rozstrzygnięcie rozdania

Po zakończeniu etapu decyzyjnego krupier odsłania swoje dwie karty własne. Zarówno gracz, jak i krupier tworzą najlepszy możliwy układ pięciokartowy z siedmiu

Tabela 2.3. Dostępne decyzje gracza w Ultimate Texas Hold'em

Etap	Dostępne akcje	Wysokość zakładu Play
Preflop	check / raise	3x lub 4x Ante
Flop	check / raise	2x Ante
River	fold / raise	1x Ante

dostępnych kart: dwóch kart własnych oraz pięciu kart wspólnych. Następnie układy są porównywane zgodnie ze standardowym rankingiem układów pokerowych.

Krupier kwalifikuje się do gry, jeżeli posiada co najmniej parę. Jeżeli krupier się nie kwalifikuje, zakład Ante jest zwracany graczowi. Zakład Play jest rozliczany na podstawie bezpośredniego porównania układu gracza i krupiera. W przypadku zwycięstwa gracza Play wypłacany jest w stosunku 1:1, w przypadku przegranej gracz traci zakład Play, a w przypadku remisu zakład jest zwracany [1], [3].

Zakład Blind ma odrębną logikę rozliczania. Jeżeli gracz pokona krupiera układem o wartości co najmniej strita, Blind wypłacany jest zgodnie z tabelą wypłat. Jeżeli gracz wygra rozdanie układem słabszym niż strit, zakład Blind jest zwracany. W przypadku przegranej gracza zakład Blind jest tracony, a w przypadku remisu zwracany [1].

2.4.6. Zakłady poboczne

W wielu wariantach Ultimate Texas Hold'em dostępne są również zakłady poboczne, takie jak Trips lub Progressive. Zakład Trips jest opcjonalny i wypłacany na podstawie końcowego układu gracza, niezależnie od tego, czy gracz pokonał krupiera. Najczęściej wygrywa on wtedy, gdy końcowy układ gracza ma wartość co najmniej trójki [1].

Zakłady poboczne mogą różnić się w zależności od kasyna i stosowanej tabeli wypłat.

TODO: Decyzja do potwierdzenia z promotorem: czy w podstawowym środowisku uwzględnić za

W podstawowej wersji środowiska zakłady poboczne Trips oraz Progressive nie będą uwzględniane. Wynika to z faktu, że głównym celem pracy jest modelowanie sekwencyjnego procesu decyzyjnego dotyczącego zakładu Play. Zakłady poboczne są opcjonalne, zależą od tabel wypłat konkretnego kasyna i zwiększają wariancję wyniku, nie zmieniając podstawowej struktury decyzji: check, raise albo fold.

2.4.7. Tabele wypłat

Zakład Blind nie jest wypłacany dla każdego zwycięskiego układu gracza. Zgodnie z tabelą wypłat, bonus na zakładzie Blind wypłacany jest wtedy, gdy gracz pokona krupiera i posiada układ o wartości co najmniej strita. Jeżeli gracz pokona krupiera układem słabszym niż strit, zakład Blind jest zwracany. Tabelę wypłat zakładu Blind

przedstawiono w tabeli 2.4 [1].

Tabela 2.4. Tabela wypłat zakładu Trips przyjęta w modelu środowiska

Układ gracza	Wypłata
Poker królewski	500:1
Poker	50:1
Kareta	10:1
Full	3:1
Kolor	3:2
Strit	1:1
Pozostałe układy	Zwrot

Zakład Trips jest opcjonalnym zakładem pobocznym. Jest on rozliczany na podstawie końcowego układu gracza i nie zależy od tego, czy gracz pokonał krupiera. W analizowanym przykładzie zakład Trips wygrywa wtedy, gdy gracz uzyska układ co najmniej trójki. Przykładową tabelę wypłat zakładu Trips przedstawiono w tabeli 2.5 [1].

Tabela 2.5. Przykładowa tabela wypłat zakładu Trips w Ultimate Texas Hold'em

Układ gracza	Wypłata
Poker królewski	50:1
Poker	40:1
Kareta	30:1
Full	8:1
Kolor	7:1
Strit	4:1
Trójka	3:1

W niektórych wariantach gry dostępny jest również zakład Progressive, którego tabela wypłat zależy od konkretnego kasyna oraz wartości puli progresywnej. Ze względu na zależność od zewnętrznych zasad kasynowych oraz brak bezpośredniego związku z podstawową decyzją Play, zakład ten nie będzie uwzględniany w podstawowym modelu środowiska.

2.5. Wartość oczekiwana, house edge i strategia bazowa

Wartość oczekiwana (ang. *expected value*, EV) określa średni wynik finansowy decyzji lub strategii przy założeniu dużej liczby powtórzeń gry. W kontekście Ultimate Texas Hold'em pojedyncze rozdanie może zakończyć się zarówno zyskiem, jak i stratą, jednak jakość strategii należy oceniać na podstawie średniego wyniku uzyskiwanego w wielu rozdaniach.

Przewaga kasyna (ang. *house edge*) jest matematyczną miarą określającą oczekiwany zysk kasyna względem zakładu gracza. Nie oznacza ona, że kasyno wygrywa każde

pojedyncze rozdanie, lecz że przy dużej liczbie rozegranych rozdań średni wynik będzie przesuwał się na korzyść kasyna. Gracz może więc osiągać krótkoterminowe zyski, jednak w długim okresie wynik gry powinien zbliżać się do wartości oczekiwanej wynikającej z zasad gry [4].

Istotne jest również to, że przewaga kasyna odnosi się do kwoty postawionych zakładów, a nie wyłącznie do początkowego kapitału gracza (ang. *bankroll*). Jeżeli gracz wykonuje wiele zakładów w kolejnych rozdaniach, całkowita kwota zaangażowana w grę może być wielokrotnie większa niż początkowy kapitał. Z tego powodu nawet niewielka procentowa przewaga kasyna może prowadzić do istotnej oczekiwanej straty w długim horyzoncie czasowym [4].

W grach takich jak Ultimate Texas Hold'em interpretacja house edge wymaga dodatkowej ostrożności, ponieważ gracz oprócz zakładów początkowych może zwiększać swoje zaangażowanie poprzez zakład Play. Z tego powodu oprócz klasycznej przewagi kasyna można analizować również miarę określaną jako element ryzyka (ang. *element of risk*), odnoszącą średnią stratę do całkowitej kwoty postawionej w rozdaniu [3], [5].

Przykładowe wartości przewagi kasyna dla wybranych gier przedstawiono w tabeli 2.6 [5].

Tabela 2.6. Przykładowe wartości przewagi kasyna dla wybranych gier kasynowych

Gra	Przewaga kasyna
Blackjack	0,28%
Ultimate Texas Hold'em	2,19%
Ruletka europejska	2,70%
Ruletka amerykańska	5,26%
Slot machines	2–15%

Tabela 2.6 pokazuje, że przewaga kasyna jest cechą konstrukcyjną gier hazardowych, ale jej poziom istotnie różni się pomiędzy grami. Celem niniejszej pracy nie jest wykazanie, że agent może trwale uzyskać dodatnią wartość oczekiwaną w grze zaprojektowanej na korzyść kasyna, lecz sprawdzenie, które metody uczenia przez wzmacnianie są w stanie nauczyć się strategii minimalizującej tę przewagę.

2.6. Uczenie przez wzmacnianie

Uczenie przez wzmacnianie (ang. *reinforcement learning*, RL) jest paradygmatem uczenia maszynowego, w którym agent uczy się podejmowania decyzji poprzez interakcję ze środowiskiem. W każdym kroku agent obserwuje aktualny stan (ang. *state*) środowiska, wybiera akcję (ang. *action*), a następnie otrzymuje nagrodę (ang. *reward*) oraz przechodzi do kolejnego stanu. Celem agenta jest wyuczenie strategii, określanej również jako polityka decyzyjna (ang. *policy*), która maksymalizuje sumę nagród w długim horyzoncie czasowym.

W przypadku Ultimate Texas Hold'em środowiskiem jest symulator gry, stanem jest aktualna sytuacja w rozdaniu, akcją jest decyzja gracza, natomiast nagrodą może być końcowy wynik finansowy rozdania. Takie sformułowanie pozwala traktować grę jako problem sekwencyjnego podejmowania decyzji, w którym agent uczy się kompromisu pomiędzy ryzykiem, ilością dostępnej informacji oraz potencjalną wysokością wypłaty.

Z perspektywy uczenia przez wzmocnianie Ultimate Texas Hold'em jest interesującym środowiskiem, ponieważ decyzje gracza są sekwencyjne i podejmowane przy różnym poziomie dostępnej informacji. Przed flopem gracz zna jedynie swoje dwie karty, ale może wykonać najwyższy zakład Play. Po flopie posiada więcej informacji, lecz maksymalny zakład jest mniejszy. Po odkryciu wszystkich kart wspólnych zna już pełny board, ale może wykonać wyłącznie zakład 1x Ante albo spasować. Agent musi więc nauczyć się kompromisu pomiędzy ryzykiem, ilością informacji oraz potencjalną wypłatą.

3. Projekt i implementacja środowiska Ultimate Texas Hold'em

W niniejszym rozdziale przedstawiono projekt oraz implementację środowiska Ultimate Texas Hold'em wykorzystywanego w dalszej części pracy do uczenia i oceny agentów. Opisane wcześniej zasady gry zostały odwzorowane w postaci deterministycznego i testowalnego silnika, który zarządza przebiegiem rozdania, udostępnia agentowi legalne akcje oraz rozlicza wynik finansowy rozgrywki.

Szczególną uwagę poświęcono zachowaniu niepełnej informacji charakterystycznej dla pokera. Agent otrzymuje wyłącznie informacje, które byłyby dostępne rzeczywistemu graczowi, natomiast karty krupiera, karty spalone oraz kolejność pozostałych kart w talii pozostają elementami wewnętrznego stanu środowiska. Takie rozdzielenie pozwala ograniczyć ryzyko niezamierzonego ujawnienia informacji podczas uczenia modeli.

Implementację podzielono na niezależne moduły odpowiedzialne między innymi za reprezentację kart, ocenę układów, sterowanie przebiegiem rozdania, walidację akcji oraz rozliczanie zakładów. Silnik domenowy nie zależy bezpośrednio od biblioteki Gymnasium. Adapter zgodny z jej interfejsem zostanie utworzony jako osobna warstwa, co umożliwi późniejsze porównywanie różnych reprezentacji stanu i funkcji nagrody bez modyfikowania zasad gry.

3.1. Założenia projektowe środowiska

Podstawową jednostką interakcji ze środowiskiem jest jedno kompletne rozdanie. Rozdanie rozpoczyna się od utworzenia talii i przekazania graczowi oraz krupierowi po dwóch kart własnych, a kończy się spasowaniem gracza albo automatycznym rozstrzygnięciem układów. Z punktu widzenia uczenia przez wzmacnianie pojedyncze rozdanie stanowi jeden epizod.

Agent podejmuje decyzje wyłącznie w trzech etapach: przed flopem, po odkryciu flopa oraz po odkryciu wszystkich pięciu kart wspólnych. W zależności od etapu może czekać, wykonać zakład Play o odpowiednim mnożniku albo spasować. Po wykonaniu zakładu Play środowisko automatycznie odkrywa pozostałe karty, ocenia ręce gracza i krupiera oraz przechodzi do stanu końcowego. W ramach jednego rozdania zakład Play może zostać wykonany tylko raz.

Środowisko modeluje podstawowy wariant Ultimate Texas Hold'em obejmujący zakłady Ante, Blind oraz Play. Zakłady boczne Trips i Progressive zostały pominięte. Nie wpływają one na przestrzeń decyzji podstawowej gry, natomiast zmieniają rozkład wyników finansowych i utrudniają ocenę jakości strategii decyzyjnej agenta. Uzasadnienie tego ograniczenia przedstawiono szerzej w dalszej części rozdziału.

Wartości zakładów wyrażono w jednostkach względnych, gdzie jedna jednostka odpowiada wartości zakładu Ante. Zakłady Ante i Blind mają zatem wartość jednej jednostki, natomiast wartość zakładu Play zależy od momentu jego wykonania i może wynosić od jednej do czterech jednostek. Takie rozwiązanie uniezależnia środowisko od konkretnej waluty i nominalnej wysokości stawki, a także ułatwia porównywanie wyników pomiędzy eksperymentami.

Silnik zwraca szczegółowe rozliczenie poszczególnych zakładów oraz łączny wynik netto rozdania. W podstawowym wariancie środowiska przeznaczonym dla agentów uczących się wynik netto będzie wykorzystywany jako nagroda terminalna. W krokach pośrednich nagroda wynosi zero. Rozdzielenie mechanizmu rozliczania gry od funkcji nagrody umożliwia późniejsze badanie alternatywnych wariantów nagrody bez ingerencji w reguły Ultimate Texas Hold'em.

Istotnym założeniem była również powtarzalność eksperymentów. Standardowa talia może być tasowana przy użyciu zadanego ziarna generatora liczb pseudolosowych, dzięki czemu możliwe jest odtworzenie całej sekwencji rozdań. W testach jednostkowych stosowana jest dodatkowo talia deterministyczna, pozwalająca jednoznacznie określić kolejność dobieranych kart i zweryfikować konkretne przypadki przebiegu oraz rozliczenia rozdania.

3.2. Architektura rozwiązania

Środowisko Ultimate Texas Hold'em zaprojektowano jako zestaw niezależnych modułów domenowych. Każdy moduł odpowiada za jeden wyraźnie określony obszar, taki jak reprezentacja kart, ocena układów, sterowanie przebiegiem rozdania albo rozliczanie zakładów. Centralnym elementem rozwiązania jest klasa `UTHGame`, która koordynuje działanie pozostałych komponentów, ale nie implementuje bezpośrednio wszystkich reguł gry.

Przyjęty podział ogranicza zależności pomiędzy poszczególnymi częściami systemu. Model kart i evaluator układów mogą być rozwijane oraz testowane niezależnie od zasad Ultimate Texas Hold'em. Analogicznie mechanizm rozliczania zakładów nie odpowiada za odkrywanie kart ani za walidację dozwolonych akcji. Dzięki temu zmiana jednego elementu, na przykład reprezentacji obserwacji agenta, nie wymaga modyfikowania sposobu oceny układów lub obliczania wypłat.

Najniższą warstwę rozwiązania stanowią moduły `cards` i `hands`. Pierwszy z nich definiuje karty oraz talię, natomiast drugi odpowiada za ocenę i porównywanie układów pokerowych. Moduły te nie zawierają reguł charakterystycznych dla Ultimate Texas Hold'em i mogą zostać ponownie wykorzystane w innych odmianach pokera.

Warstwę domenową gry tworzy pakiet `uth`. Zawiera on modele stanu, reguły legalności akcji, mechanizm rozdawania kart, sposób rozliczania zakładów oraz logikę sterującą kolejnymi fazami rozdania. Klasa `UTHGame` pełni rolę koordynatora tej war-

stwy. Na podstawie aktualnego stanu i wybranej akcji wywołuje odpowiednie operacje, aktualizuje stan rozdania oraz zwraca rezultat kroku.

Agent nie komunikuje się bezpośrednio z talią, evaluatorem ani pełnym stanem wewnętrznym gry. Otrzymuje obiekt `UTHObservation`, a swoją decyzję przekazuje do metody `step`. Rezultatem wykonania akcji jest obiekt `StepResult`, zawierający kolejną obserwację oraz, w przypadku zakończenia rozdania, jego wynik i szczegółowe rozliczenie. Takie rozwiązanie tworzy jednoznaczną granicę pomiędzy logiką środowiska a implementacją agenta.


Tabela 3.1 przedstawia najważniejsze moduły rozwiązania i zakres ich odpowiedzialności.

Tabela 3.1. Podział odpowiedzialności pomiędzy modułami środowiska UTH

Moduł	Odpowiedzialność
<code>cards</code>	Reprezentacja rang, kolorów, pojedynczych kart oraz standardowej talii składającej się z 52 unikalnych kart.
<code>hands</code>	Ocena pięciokartowych układów, wybór najlepszego układu z pięciu, sześciu lub siedmiu kart oraz porównywanie wartości rąk.
<code>uth.models</code>	Definicja pełnego stanu rozdania, obserwacji agenta oraz wyniku pojedynczego kroku środowiska.
<code>uth.rules</code>	Określanie zbioru legalnych akcji dla każdej fazy rozdania.
<code>uth.dealing</code>	Realizacja kolejności rozdawania kart, odkrywania flopa, turna i rivera oraz obsługa kart spalonych.
<code>uth.card_source</code>	Abstrakcja źródła kart oraz deterministyczna talia wykorzystywana w testach.
<code>uth.settlement</code>	Określanie wyniku rozdania, kwalifikacji krupiera oraz rozliczanie zakładów Ante, Blind i Play.
<code>uth.game</code>	Koordinacja przebiegu rozdania, walidacja akcji, przechodzenie pomiędzy fazami oraz tworzenie wyników kolejnych kroków.
<code>uth.trace</code>	Opcjonalne rejestrowanie obserwacji, decyzji agenta i końcowego stanu rozdania na potrzeby diagnostyki.

Silnik domenowy nie zależy od konkretnej biblioteki uczenia przez wzmocnianie. Przyszły adapter Gymnasium będzie korzystał z publicznego interfejsu `UTHGame`, przekształcając obiekty domenowe na numeryczne reprezentacje wymagane przez algorytmy uczące się. Pozwala to zachować jedną implementację zasad gry dla wszystkich badanych reprezentacji obserwacji, funkcji nagrody i metod uczenia.

Ogólny przepływ informacji pomiędzy agentem, klasą sterującą i pozostałymi elementami silnika przedstawiono na rysunku 3.1. Agent komunikuje się wyłącznie z publicznym interfejsem klasy `UTHGame`. Pełny stan rozdania oraz moduły realizujące reguły gry pozostają ukryte za tą warstwą.



Rys. 3.1. Architektura i przepływ informacji w środowisku UTH

3.2.1. Przepływ danych podczas wykonania akcji

Po rozpoczęciu rozdania metoda `reset()` zwraca pierwszą obserwację agenta. Na jej podstawie agent wybiera akcję należącą do zbioru akcji legalnych w aktualnej fazie gry. Wybrana wartość jest następnie przekazywana do metody `step()`, która realizuje pojedyncze przejście środowiska.

W pierwszej kolejności silnik sprawdza, czy rozdanie nie zostało już zakończone, czy przekazana wartość jest poprawnym obiektem reprezentującym akcję oraz czy dana akcja jest legalna w aktualnej fazie. Odrzucenie niepoprawnej akcji następuje przed jakąkolwiek zmianą stanu lub pobraniem kart z talii. Zapobiega to częściowemu wykonaniu niedozwolonego przejścia.

Po pozytywnej walidacji sterowanie jest przekazywane do operacji właściwej dla aktualnej fazy: preflop, flopa albo rivera. Akcja oczekiwania powoduje odkrycie kart wymaganych do przejścia do następnej fazy. Wykonanie zakładu Play prowadzi natomiast do odkrycia wszystkich pozostałych kart wspólnych, oceny układów gracza i krupiera, określenia wyniku oraz rozliczenia aktywnych zakładów. Spasowanie na riverze kończy rozdanie bez wykonywania showdownu.

Po pomyślnym przeprowadzeniu operacji tworzony jest nowy obiekt `RoundState`. Na jego podstawie budowana jest obserwacja przeznaczona dla agenta oraz obiekt `StepResult`. Wynik kroku zawiera informację, czy rozdanie zostało zakończone, a w stanie terminalnym również rezultat rozgrywki, szczegółowe rozliczenie zakładów i dane dotyczące showdownu.

Jeżeli rejestrowanie historii jest włączone, obserwacja sprzed wykonania akcji i wybrana decyzja są zapisywane jako `DecisionRecord`. Rejestracja następuje dopiero po prawidłowym zakończeniu przejścia. Jeżeli podczas odkrywania kart lub aktualizacji stanu wystąpi wyjątek, decyzja nie jest dodawana do historii, a poprzedni stan środowiska pozostaje aktualny. Rozwiązanie to zapewnia spójność pomiędzy zapisanym przebiegiem rozdania a rzeczywiście wykonanymi przejściami.

3.3. Model kart i sterowanie talią

Reprezentacja kart i mechanizm sterowania talią stanowią podstawową warstwę środowiska. Elementy te zostały zaprojektowane niezależnie od zasad Ultimate Texas Hold'em, dzięki czemu mogą być wykorzystywane także przez inne warianty pokera oraz przez moduł oceniający układy.

3.3.1. Reprezentacja karty

Pojedyncza karta jest reprezentowana przez niemodyfikowalny obiekt `Card`, zawierający dwa pola: rangę oraz kolor. Rangi zapisano za pomocą typu wyliczeniowego `Rank`, natomiast kolory za pomocą typu `Suit`. Zastosowanie typów wyliczeniowych ogranicza możliwość utworzenia karty zawierającej niepoprawną wartość.

Rangi kart przyjmują wartości liczbowe od 2 do 14. Karty od dwójki do dziesiątki zachowują swoje naturalne wartości, natomiast walet, dama, król i as otrzymują odpowiednio wartości 11, 12, 13 i 14. Przyjęta reprezentacja umożliwia bezpośrednie porównywanie rang podczas oceny układów pokerowych. W podstawowej reprezentacji as jest kartą najwyższą, natomiast szczególny przypadek strita od asa do piątki obsługiwany jest przez evaluator układów.

Zbiór kolorów obejmuje trefle, karo, kiery i piki. Każdemu kolorowi oraz każdej randze przypisano również symbol tekstowy, umożliwiający czytelne przedstawienie kart, na przykład $A\spadesuit$ lub $10\heartsuit$. Reprezentacja tekstowa jest wykorzystywana głównie w testach, diagnostyce oraz zapisie przebiegu rozdania.

Obiekty kart są niemodyfikowalne po ich utworzeniu. Pozwala to bezpiecznie umieszczać je w krotkach i zbiorach, a także wykorzystywać porównanie liczności zbioru do wykrywania zduplikowanych kart. Konstruktor dodatkowo sprawdza, czy przekazana ranga i kolor należą do odpowiednich typów wyliczeniowych.

3.3.2. Standardowa talia

Standardową talię reprezentuje klasa `Deck`. Podczas jej tworzenia generowane są wszystkie kombinacje trzynastu rang i czterech kolorów. Liczba kart w pełnej talii wynosi zatem

$$|\mathcal{D}| = 13 \cdot 4 = 52. \quad (3.1)$$

Ponieważ każda kombinacja rangi i koloru występuje dokładnie raz, wygenerowana talia zawiera 52 unikalne karty. Karty są przechowywane wewnętrznie w modyfikowalnej kolekcji, jednak publiczny podgląd zawartości talii zwracany jest w postaci krotki. Unie umożliwia to zewnętrzną zmianę kolejności lub usunięcie karty z pominięciem operacji zdefiniowanych przez talię.

Podstawową operacją jest metoda `draw()`, która pobiera jedną kartę z wierzchu

talii i jednocześnie usuwa ją z kolekcji. Dostępna jest również operacja pobrania wielu kart. Próba pobrania karty z pustej talii lub większej liczby kart niż liczba pozostałych elementów powoduje zgłoszenie wyjątku. Takie zachowanie umożliwia szybkie wykrycie niepoprawnej implementacji przebiegu rozdania.

Domyślnie talia jest tasowana bezpośrednio po utworzeniu. Możliwe jest także utworzenie talii w kolejności początkowej, co bywa użyteczne podczas testowania samego modelu kart. Tasowanie wykonywane jest przy użyciu lokalnego generatora liczb pseudolosowych, a nie globalnego stanu losowości programu.

3.3.3. Abstrakcja źródła kart

Silnik rozdania nie zależy bezpośrednio od klasy `Deck`. Zamiast tego korzysta z abstrakcji `CardSource`, która wymaga jedynie udostępnienia operacji `draw()`. Każdy obiekt spełniający ten kontrakt może zostać użyty jako źródło kolejnych kart.

Minimalny interfejs źródła kart oddziela logikę rozdania od sposobu przechowywania i wybierania kart. W normalnej rozgrywce źródłem jest pseudolosowo przetasowana talia, natomiast w testach można przekazać źródło deterministyczne. Moduł odpowiedzialny za rozdawanie wykonuje w obu przypadkach te same operacje i nie musi rozpoznawać rodzaju używanej talii.

3.3.4. Deterministyczna talia testowa

Do testowania konkretnych scenariuszy wprowadzono klasę `FixedDeck`. Podczas jej tworzenia przekazywana jest jawna sekwencja kart określająca kolejność dobierania. Pierwszy element przekazanej sekwencji jest pierwszą kartą zwracaną przez metodę `draw()`.

Przed zapisaniem sekwencji sprawdzane jest, czy wszystkie jej elementy są poprawnymi obiektami `Card` oraz czy żadna karta nie występuje więcej niż raz. Dzięki temu błąd w danych testowych nie może doprowadzić do przeprowadzenia rozdania zawierającego dwie identyczne karty.

Deterministyczne źródło umożliwia przygotowanie testów dla ściśle określonych sytuacji, takich jak:

- wygrana gracza przy niekwalifikującym się krupierze,
- remis obu stron,
- uzyskanie konkretnego układu wypłacanego przez zakład `Blind`,
- sprawdzenie kolejności kart gracza i krupiera,
- weryfikacja kart spalonych przed flopem oraz przed turnem,
- próba wykonania przejścia przy niewystarczającej liczbie kart.

Porównanie dwóch dostępnych źródeł kart przedstawiono w tabeli 3.2.

Tabela 3.2. Porównanie źródeł kart wykorzystywanych przez środowisko

Cecha	Deck	FixedDeck
Zastosowanie	Standardowe rozdania i eksperymenty	Testy deterministyczne i odtwarzanie scenariuszy
Kolejność kart	Ustalana przez tasowanie	Jawnie przekazywana podczas tworzenia
Obsługa ziarna	Tak	Nie jest wymagana
Kontrola duplikatów	Wynika ze sposobu generowania pełnej talii	Walidowana podczas tworzenia obiektu
Pierwsza dobierana karta	Wynika z kolejności po tasowaniu	Pierwszy element zadanej sekwencji

3.3.5. Powtarzalność losowych rozdań

Powtarzalność eksperymentów zapewniono przez możliwość przekazania ziarna generatora liczb pseudolosowych. Utworzenie dwóch talii z tym samym ziarnem prowadzi do uzyskania tej samej kolejności kart, o ile wykonano na nich tę samą sekwencję operacji.

Na poziomie klasy `UTHGame` zastosowano dodatkowy generator nadrzędny. Przy każdym rozpoczęciu nowego rozdania generuje on osobne ziarno przekazywane do nowej talii. W rezultacie kolejne rozdania w obrębie jednego eksperymentu różnią się od siebie, ale cała ich sekwencja może zostać odtworzona przez ponowne uruchomienie środowiska z tym samym ziarnem początkowym.

Rozwiązanie to pozwala porównywać agentów na odpowiadających sobie sekwencjach rozdań. Jeżeli dwa eksperymenty zostaną uruchomione z tym samym ziarnem środowiska i zachowają tę samą kolejność wywołań, otrzymają identyczne strumienie talii. Ogranicza to wpływ losowego doboru kart na ocenę różnic pomiędzy badanymi strategiami.

3.4. Ocena układów pokerowych

Moduł oceny układów pokerowych został zaimplementowany niezależnie od reguł Ultimate Texas Hold'em. Jego zadaniem jest określenie wartości dowolnego poprawnego układu pięciokartowego oraz wybranie najlepszej możliwej ręki z pięciu, sześciu lub siedmiu dostępnych kart. W środowisku UTH evaluator jest wykorzystywany podczas showdownu osobno dla gracza i krupiera.

Hierarchię układów pokerowych oraz ich znaczenie przedstawiono w rozdziale teoretycznym. W niniejszej sekcji opisano sposób odwzorowania tej hierarchii w implementacji oraz mechanizm jednoznacznego porównywania dwóch rąk.

3.4.1. Reprezentacja wartości ręki

Kategorię układu reprezentuje typ wyliczeniowy `HandRank`. Kolejnym kategoriom przypisano rosnące wartości liczbowe, począwszy od wysokiej karty, a kończąc na pokerze. Dzięki temu porównanie kategorii może zostać wykonane przez porównanie odpowiadających im wartości całkowitych.

Sama kategoria nie wystarcza jednak do rozstrzygnięcia wszystkich przypadków. Dwie ręce mogą należeć do tej samej kategorii, lecz różnić się rangą kart tworzących układ albo kart dodatkowych. Z tego względu pełna wartość ręki jest reprezentowana przez obiekt `HandValue`, zawierający:

- kategorię układu `rank`,
- uporządkowaną krotkę wartości rozstrzygających remis `tiebreak`.

Klucz porównawczy ręki można zapisać jako

$$K(h) = (r(h), t_1(h), t_2(h), \dots, t_n(h)), \quad (3.2)$$

gdzie $r(h)$ oznacza wartość kategorii układu, natomiast $t_1(h), \dots, t_n(h)$ są kolejnymi wartościami rozstrzygającymi remis. Dwa klucze porównywane są leksykograficznie. W pierwszej kolejności porównywana jest kategoria układu, a dopiero w przypadku jej równości kolejne elementy krotki `tiebreak`.

Przykładowo wartość pary asów z królem, dziesiątką i dziewiątką jako kartami dodatkowymi może zostać zapisana w postaci

$$K(h) = (\text{ONE_PAIR}, 14, 13, 10, 9). \quad (3.3)$$

Jeżeli druga ręka również zawiera parę asów, porównanie przechodzi kolejno do króla, dziesiątki i dziewiątki. Kolory kart nie uczestniczą w rozstrzyganiu remisów, zgodnie ze standardowymi zasadami pokera.

Sposób budowy krotki rozstrzygającej dla każdej kategorii przedstawiono w tabeli 3.3.

Obiekt `HandValue` sprawdza zgodność długości krotki `tiebreak` z kategorią układu. Walidowane jest również, czy wszystkie jej elementy są liczbami całkowitymi odpowiadającymi poprawnym rangom kart. Ogranicza to możliwość utworzenia wartości ręki, która nie mogłaby powstać w prawidłowym rozdaniu.

3.4.2. Ocena układu pięciokartowego

Funkcja `evaluate_five_card_hand()` przyjmuje dokładnie pięć unikalnych kart. Przed rozpoczęciem oceny sprawdzana jest liczba kart, typ każdego elementu oraz brak duplikatów.

Tabela 3.3. Wartości wykorzystywane do rozstrzygania remisów

Kategoria	Liczba wartości	Kolejność elementów tiebreak
Wysoka karta	5	Wszystkie rangi w kolejności malejącej.
Jedna para	4	Ranga pary, a następnie trzy pozostałe rangi malejąco.
Dwie pary	3	Wyższa para, niższa para oraz karta dodatkowa.
Trójka	3	Ranga trójki oraz dwie pozostałe rangi malejąco.
Strit	1	Ranga najwyższej karty strita.
Kolor	5	Wszystkie rangi w kolejności malejącej.
Full	2	Ranga trójki, a następnie ranga pary.
Kareta	2	Ranga karety oraz ranga karty dodatkowej.
Poker	1	Ranga najwyższej karty pokera.

W pierwszym kroku obliczana jest liczba wystąpień każdej rangi. Na tej podstawie możliwe jest wykrycie par, dwóch par, trójki, fulla oraz karety. Niezależnie sprawdzane są dwa warunki:

- czy wszystkie karty mają ten sam kolor,
- czy pięć różnych rang tworzy ciąg kolejnych wartości.

Kategorie sprawdzane są od najsilniejszej do najsłabszej. Jeżeli spełnione są jednocześnie warunki strita i koloru, zwracany jest poker. W przeciwnym razie sprawdzane są kolejno kareta, full, kolor, strit, trójka, dwie pary, jedna para oraz wysoka karta.

Wartość tiebreak jest budowana bezpośrednio podczas rozpoznawania kategorii. Wynikiem funkcji nie jest zatem jedynie nazwa układu, lecz kompletna wartość umożliwiająca porównanie z dowolną inną poprawną ręką.

3.4.3. Obsługa niskiego strita z asem

W podstawowym modelu rang as otrzymuje wartość 14 i jest najwyższą kartą. W przypadku strita A-2-3-4-5 musi jednak pełnić funkcję karty niższej od dwójki. Układ ten jest obsługiwany jako szczególny przypadek.

Dla zestawu rang

$$\{14, 5, 4, 3, 2\} \quad (3.4)$$

evaluator zwraca strita o najwyższej karcie równej 5. Jego klucz porównawczy jest zatem słabszy od klucza strita zakończonego szóstką. Pozwala to zachować naturalną kolejność wszystkich możliwych stritów bez zmieniania podstawowej wartości asa w pozostałych kategoriach.

3.4.4. Wybór najlepszej ręki

Podczas showdownu gracz i krupier dysponują łącznie siedmioma kartami: dwiema kartami własnymi oraz pięcioma kartami wspólnymi. Rękę pokerową tworzy jednak dokładnie pięć kart. Funkcja `evaluate_best_hand()` generuje wszystkie możliwe pięciokartowe podzbiory dostępnych kart, ocenia każdy z nich, a następnie wybiera układ o największej wartości `HandValue`.

Liczba sprawdzanych kombinacji dla n dostępnych kart wynosi

$$N(n) = \binom{n}{5}. \quad (3.5)$$

Dla liczby kart obsługiwanych przez evaluator otrzymuje się:

$$\binom{5}{5} = 1, \quad \binom{6}{5} = 6, \quad \binom{7}{5} = 21. \quad (3.6)$$

W przypadku standardowego showdownu UTH konieczne jest zatem sprawdzenie 21 kombinacji dla gracza oraz 21 kombinacji dla krupiera. Ze względu na niewielką i stałą liczbę możliwości pełne przeszukanie jest wystarczająco proste, jednoznaczne oraz łatwe do zweryfikowania w testach. Nie było potrzeby stosowania bardziej złożonego, specjalizowanego algorytmu ewaluacji.

Przed wygenerowaniem kombinacji sprawdzane jest, czy przekazano od pięciu do siedmiu kart, czy wszystkie elementy są kartami oraz czy żadna karta nie występuje więcej niż raz.

Wynikiem operacji jest obiekt `EvaluatedHand`, który przechowuje zarówno wartość `HandValue`, jak i dokładnie pięć kart tworzących wybrany układ. Zachowanie kart składowych jest przydatne podczas:

- prezentowania wyniku showdownu,
- analizy decyzji agentów,
- diagnozowania błędów evaluatora,
- identyfikowania rzadkich lub szczególnie wartościowych rozdań.

Poker królewski nie stanowi osobnej kategorii `HandRank`. Jest reprezentowany jako poker z asem jako najwyższą kartą. Obiekt `HandValue` udostępnia właściwość pozwalającą rozpoznać ten przypadek, co jest potrzebne przy naliczaniu najwyższej wypłaty zakładu `Blind`.

3.5. Stan wewnętrzny i obserwacja agenta

Ultimate Texas Hold'em jest grą z niepełną informacją. W momencie podejmowania decyzji gracz zna własne karty oraz dotychczas odkryte karty wspólne, ale nie

zna kart krupiera, kart spalonych ani kolejności pozostałych kart w talii. Poprawne odwzorowanie tej własności wymaga rozdzielenia pełnego stanu środowiska od informacji udostępnianych agentowi.

W implementacji zastosowano dwa odrębne modele danych:

- `RoundState`, reprezentujący pełny stan wewnętrzny rozdania,
- `UTHObservation`, reprezentujący obserwację dostępną agentowi.

Agent nie otrzymuje bezpośredniego odwołania do obiektu `RoundState`. Każda obserwacja jest tworzona na jego podstawie przez osobną funkcję projekcji, która kopiuje wyłącznie informacje dozwolone z perspektywy gracza.

3.5.1. Pełny stan rozdania

Obiekt `RoundState` zawiera wszystkie dane potrzebne do kontynuowania i rozstrzygnięcia rozdania. Obejmuje on:

- aktualną fazę gry,
- dwie karty własne gracza,
- dwie ukryte karty krupiera,
- odkryte karty wspólne,
- karty spalone,
- mnożnik wykonanego zakładu `Play`,
- końcowy wynik rozdania,
- szczegółowe rozliczenie zakładów,
- rezultat showdownu.

Nie wszystkie pola są aktywne jednocześnie. W stanach pośrednich wynik rozdania, rozliczenie, rezultat showdownu oraz mnożnik zakładu `Play` pozostają nieokreślone. Pola te otrzymują wartości dopiero po przejściu do stanu terminalnego.

Liczba kart wspólnych i spalonych jest uzależniona od aktualnej fazy. Zależność tę przedstawiono w tabeli 3.4.

Obiekt stanu jest niemodyfikowalny. Każde przejście środowiska prowadzi do utworzenia nowej instancji `RoundState`, zamiast modyfikowania istniejącego obiektu. Upraszcza to analizę przejść, ogranicza ryzyko częściowej aktualizacji oraz ułatwia tworzenie deterministycznych testów.

Podczas tworzenia stanu sprawdzane są między innymi:

Tabela 3.4. Liczba kart przechowywanych w stanie w poszczególnych fazach

Faza	Karty wspólne	Karty spalone	Znaczenie
PREFLOP	0	0	Rozdano wyłącznie karty własne gracza i krupiera.
FLOP	3	1	Spalono jedną kartę i odkryto flop.
RIVER	5	2	Odkryto komplet kart wspólnych.
TERMINAL	5	2	Rozdanie zostało zakończone foldem albo showdownem.

- poprawny typ fazy,
- obecność dokładnie dwóch kart gracza i dwóch kart krupiera,
- liczba kart wspólnych właściwa dla danej fazy,
- liczba kart spalonych właściwa dla danej fazy,
- brak zduplikowanych kart w całym stanie,
- zgodność pól końcowych z fazą rozdania.

Walidacja obejmuje również zależności semantyczne pomiędzy polami. Stan niekońcowy nie może zawierać wyniku ani rozliczenia. Stan zakończony foldem nie może zawierać mnożnika Play ani rezultatu showdownu. Z kolei stan zakończony showdownem musi zawierać zarówno mnożnik wykonanego zakładu, jak i szczegóły ocenionych rąk.

3.5.2. Obserwacja agenta

Obiekt `UTH0bservation` zawiera wyłącznie dane, które mogą zostać wykorzystane przez agenta podczas podejmowania decyzji. Są to:

- aktualna faza gry,
- dwie karty własne gracza,
- dotychczas odkryte karty wspólne,
- zbiór legalnych akcji,
- mnożnik zakładu Play w obserwacji terminalnej.

Obserwacja celowo nie zawiera:

- kart krupiera,

- kart spalonych,
- pozostałych kart w talii,
- kolejności przyszłego dobierania kart,
- wyniku ewaluacji ręki krupiera przed zakończeniem rozdania.

Zbiór legalnych akcji jest umieszczony bezpośrednio w obserwacji. Agent nie musi zatem samodzielnie odtwarzać zasad gry na podstawie fazy. Rozwiązanie to ułatwia implementację agentów bazowych, a w przyszłym adapterze Gymnasium umożliwi utworzenie maski akcji.

Obserwacja, podobnie jak pełny stan, jest obiektem niemodyfikowalnym. Sprawdzana jest liczba widocznych kart, brak duplikatów oraz zgodność zbioru legalnych akcji z aktualną fazą gry. Dzięki temu błędnie skonstruowana obserwacja jest odrzucana przed przekazaniem jej agentowi.

3.5.3. Projekcja stanu na obserwację

Proces tworzenia obserwacji można przedstawić jako funkcję projekcji

$$O_t = \phi(S_t), \quad (3.7)$$

gdzie S_t jest pełnym stanem środowiska w chwili t , natomiast O_t oznacza obserwację udostępnioną agentowi.

Dla zaimplementowanego środowiska projekcja ma postać

$$\phi(S_t) = (p_t, C_t^{player}, C_t^{community}, A_t^{legal}, m_t), \quad (3.8)$$

gdzie:

- p_t oznacza aktualną fazę gry,
- C_t^{player} oznacza karty własne gracza,
- $C_t^{community}$ oznacza odkryte karty wspólne,
- A_t^{legal} oznacza zbiór legalnych akcji,
- m_t oznacza mnożnik zakładu Play, jeżeli został już wykonany.

Elementy takie jak karty krupiera, karty spalone i zawartość pozostałej talii należą do S_t , ale nie są elementami O_t .

Porównanie zawartości pełnego stanu i obserwacji przedstawiono w tabeli 3.5.

Wynik rozdania, rozliczenie i szczegóły showdownu są po zakończeniu epizodu zwracane przez obiekt `StepResult`, a nie przez samą obserwację. Informacje te pojawiają

Tabela 3.5. Porównanie pełnego stanu środowiska i obserwacji agenta

Informacja	RoundState	UTHObservation
Aktualna faza	tak	tak
Karty własne gracza	tak	tak
Odkryte karty wspólne	tak	tak
Karty krupiera	tak	nie
Karty spalone	tak	nie
Kolejność pozostałej talii	dostępna wewnętrznie silnikowi	nie
Legalne akcje	wyznaczane na podstawie fazy	tak
Mnożnik zakładu Play	tak	tylko po wykonaniu zakładu
Końcowy wynik rozdania	tak	nie
Szczegółowe rozliczenie	tak	nie
Szczegóły showdownu	tak	nie

się dopiero po wykonaniu ostatniej decyzji, dlatego nie mogą wpłynąć na wybór akcji w bieżącym rozdaniu.

3.5.4. Ochrona przed wyciekami informacji

Rozdzielenie stanu i obserwacji pełni rolę ochrony przed wyciekami informacji ukrytej. Funkcja tworząca obserwację nie usuwa niepożądanych pól z kopii pełnego stanu. Zamiast tego jawnie konstruuje nowy obiekt, przekazując wyłącznie dozwolone wartości.


Podjęcie to można określić jako tworzenie obserwacji zgodnie z listą dozwolonych informacji. Jest ono bezpieczniejsze niż stosowanie listy pól zabronionych. Po dodaniu nowego pola do RoundState nie zostanie ono automatycznie ujawnione agentowi. Aby znalazło się w obserwacji, musi zostać jawnie dodane do modelu UTHObservation oraz do funkcji projekcji.

Istotne jest również rozróżnienie pomiędzy interfejsem przeznaczonym dla agenta a interfejsem diagnostycznym. Pełny stan może być wykorzystywany przez testy, rejestrowanie przebiegu rozdania i analizę zakończonych epizodów, ale nie powinien być przekazywany metodzie wybierającej akcję agenta.

Granica pomiędzy pełnym stanem środowiska a informacjami przekazywanymi agentowi została przedstawiona na rysunku 3.2. Obserwacja nie jest bezpośrednim widokiem pełnego stanu, lecz wynikiem jawnie zdefiniowanej projekcji. Informacje ukryte pozostają dostępne wyłącznie wewnętrznym komponentom środowiska.

Informacje ukryte są częścią stanu potrzebnego do poprawnego prowadzenia gry, lecz nie uczestniczą w tworzeniu obserwacji. Przykładowo silnik musi przechowywać karty krupiera, aby po zakończeniu rozdania przeprowadzić showdown, ale agent nie może korzystać z nich podczas wyboru akcji.

Podobnie karty spalone i kolejność pozostałych kart są potrzebne do kontynuowania rozdania oraz zapewnienia jego deterministycznego odtworzenia, jednak ich ujawnie-



Rys. 3.2. Oddzielenie pełnego stanu środowiska od obserwacji agenta

nie zmieniałoby problem decyzyjny. Agent znałby wówczas przyszłe zdarzenia losowe, co prowadziłoby do sztucznie zawyżonej jakości strategii.

Jawna funkcja projekcji stanowi zatem część definicji środowiska z niepełną informacją. Zapewnia ona, że każda metoda wyboru akcji, niezależnie od zastosowanego algorytmu, otrzymuje ten sam zakres informacji. W przyszłych eksperymentach zmianie może podlegać sposób numerycznego kodowania obserwacji, natomiast zbiór informacji dostępnych agentowi pozostanie niezmienny.

Spis rysunków

3.1	Architektura i przepływ informacji w środowisku UTH	18
3.2	Oddzielenie pełnego stanu środowiska od obserwacji agenta	29

Spis tabel

2.1	Ranking układów pokerowych od najsilniejszego do najłabszego	8
2.2	Porównanie Texas Hold'em i Ultimate Texas Hold'em	9
2.3	Dostępne decyzje gracza w Ultimate Texas Hold'em	10
2.4	Tabela wypłat zakładu Trips przyjęta w modelu środowiska	11
2.5	Przykładowa tabela wypłat zakładu Trips w Ultimate Texas Hold'em . .	11
2.6	Przykładowe wartości przewagi kasyna dla wybranych gier kasynowych . .	12
3.1	Podział odpowiedzialności pomiędzy modułami środowiska UTH	17
3.2	Porównanie źródeł kart wykorzystywanych przez środowisko	21
3.3	Wartości wykorzystywane do rozstrzygania remisów	23
3.4	Liczba kart przechowywanych w stanie w poszczególnych fazach	26
3.5	Porównanie pełnego stanu środowiska i obserwacji agenta	28

Bibliografia

- [1] Tulalip Resort Casino, *Ultimate Texas Hold'em Game Rules*, https://www.everythingtulalip.com/wp-content/uploads/2024/04/ONEclub_0920_GameRules_RackCard_UltimateTexasHoldem-WEB.pdf, Dostęp: 2026-07-12.
- [2] Nevada Gaming Control Board, *Ultimate Texas Hold'em - Rules of Play*, https://www.gaming.nv.gov/siteassets/content/divisions/enforcement/rules-of-play/Ultimate_Texas_Hold_em.pdf, Dostęp: 2026-07-07.
- [3] W. of Odds, *Ultimate Texas Hold'em*, <https://wizardofodds.com/games/ultimate-texas-hold-em/>, Dostęp: 2026-07-07.
- [4] J. B. Maverick, *Understanding the House Edge: How Casinos Ensure Profit*, <https://www.investopedia.com/articles/personal-finance/110415/why-does-house-always-win-look-casino-profitability.asp>, Dostęp: 2026-07-12.
- [5] Wizard of Odds, *What is the House Edge?* <https://wizardofodds.com/gambling/house-edge/>, Dostęp: 2026-07-12.