




Politechnika Krakowska
im. Tadeusza Kościuszki
Wydział Informatyki i Telekomunikacji



Michał Bąk

Numer albumu: 144753

Porównanie metod uczenia przez wzmacnianie w Ultimate Texas Hold'em z niepełną informacją: wpływ reprezentacji stanu i funkcji nagrody na jakość strategii

Comparison of reinforcement learning methods in Ultimate Texas Hold'em under imperfect information: the impact of state representation and reward function on strategy quality

Praca dyplomowa magisterska
na kierunku Informatyka

Praca wykonana pod kierunkiem:
mgr inż. Piotr Biskup

Kraków, 2026

SPIS TREŚCI

1	Wstęp	3
1.1	Cel pracy	3
1.2	Zakres pracy	3
1.3	Problem badawczy	4
1.4	Struktura pracy	4
2	Podstawy teoretyczne	7
2.1	Poker jako gra z niepełną informacją	7
2.2	Texas Hold'em	7
2.3	Ranking układów pokerowych	7
2.4	Ultimate Texas Hold'em	8
2.4.1	Charakterystyka gry	8
2.4.2	Przebieg rozdania	8
2.4.3	Zakłady i decyzje gracza	9
2.4.4	Rozstrzyganie rozdania	9
2.4.5	Zakłady poboczne	10
2.5	Wartość oczekiwana i przewaga kasyna	10
2.6	Strategie bazowe i ocena jakości strategii	11
2.7	Uczenie przez wzmacnianie	11
2.7.1	Podstawowe pojęcia	11
2.8	Modelowanie UTH jako procesu decyzyjnego	12

1. Wstęp

Od zawsze interesowały mnie gry karciane jako obszar zastosowania metod sztucznej inteligencji, ponieważ łączą w sobie elementy losowości oraz podejmowania decyzji przy niepełnej informacji. W klasycznych problemach uczenia maszynowego model uczy się na podstawie gotowego zbioru danych, a w grach agent musi samodzielnie podejmować decyzje, obserwować ich konsekwencje i poprawiać swoją strategię.

Szczególnie interesującym mnie przypadkiem są gry pokerowe, w których wynik pojedynczego rozdania nie zależy jedynie od posiadanych kart, ale również od decyzji podjętych w ramach kolejnych etapów gry. Chciałbym zwrócić uwagę na Ultimate Texas Hold'em - kasynową odmianę pokera bazującą na zasadach Texas Hold'em, w której gracz rywalizuje nie z innymi graczami, a z krupierem. Odmiana ta ma ograniczoną liczbę możliwych akcji, jasno określone reguły wypłat oraz sekwencyjny przebieg rozdania. Te cechy, w moim mniemaniu, czynią ją odpowiednim problemem do rozważenia w ramach uczenia przez wzmacnianie.

Uczenie przez wzmacnianie (ang. *reinforcement learning*, RL) pozwala analizować sytuacje, w których agent uczy się strategii poprzez interakcję ze środowiskiem. W przypadku Ultimate Texas Hold'em środowiskiem może być symulator gry, obserwacją informacje dostępne graczowi w bieżącym etapie rozdania, akcją decyzja gracza, natomiast nagrodą końcowy wynik finansowy rozdania. Takie podejście umożliwia badanie, w jaki sposób różne reprezentacje stanu oraz różne definicje funkcji nagrody wpływają na jakość wyuczonej strategii.

1.1. Cel pracy

Głównym celem tej pracy jest ocena przydatności wybranych metod uczenia przez wzmacnianie do podejmowania decyzji w Ultimate Texas Hold'em. Analizie podlega również wpływ sposobu reprezentacji obserwacji oraz konstrukcji funkcji nagrody na przebieg uczenia i jakość otrzymywanej strategii.

Za cel praktyczny obrałem zaprojektowanie i implementację kompletnego procesu badawczego obejmującego środowisko gry, agentów bazowych i uczących się, mechanizm prowadzenia treningu oraz powtarzalną ocenę uzyskanych strategii. Porównanie zawiera różnice pomiędzy metodami uczenia, jak i ich odniesienie do strategii bazowych, w tym agenta losowego i agenta regułowego.

1.2. Zakres pracy

Zakres pracy obejmuje zaprojektowanie i implementację środowiska odwzorowującego podstawowy wariant Ultimate Texas Hold'em, w którym uwzględniłem podstawowe elementy rozgrywki: karty gracza i krupiera, karty wspólne, obowiązkowe zakłady Ante

i Blind oraz decyzyjny zakład Play. W mojej wersji środowiska pominąłem zakłady poboczne, takie jak Trips oraz Progressive, ponieważ nie są one bezpośrednio związane z głównym procesem decyzyjnym agenta.

W ramach pracy przygotowałem różne warianty numerycznej reprezentacji obserwacji agenta, utworzonej na podstawie dostępnej części stanu gry. Reprezentacja obserwacji obejmuje między innymi informacje o kartach gracza, kartach wspólnych, aktualnym etapie rozdania oraz dostępnych akcjach. Podałem analizie również wpływ sposobu przekształcania finansowego wyniku rozdania w sygnał nagrody.

Założenia niniejszej pracy są następujące:

1. Implementacja środowiska odwzorowującego podstawowy wariant UTH.
2. Implementacja mechanizmu oceny układów, przebiegu rozdania i rozliczania zakładów.
3. Przygotowanie agentów bazowych (ang. *baseline agents*) stanowiących punkty odniesienia dla metod uczących się.
4. Implementacja wybranych metod uczenia przez wzmacnianie.
5. Przygotowanie i porównanie różnych reprezentacji obserwacji.
6. Przygotowanie i porównanie wybranych funkcji nagrody.
7. Opracowanie powtarzalnej procedury treningu i oceny agentów.
8. Analiza jakości strategii, przebiegu uczenia oraz wyników uzyskanych względem pozostałych metod i strategii bazowych.

1.3. Problem badawczy

Problem badawczy, który postanowiłem rozważyć, dotyczy wpływu wyboru metody uczenia przez wzmacnianie, reprezentacji obserwacji oraz funkcji nagrody na przebieg uczenia oraz jakość strategii uzyskiwanej w Ultimate Texas Hold'em.

Analizie poddałem także to, które konfiguracje pozwalają osiągnąć najwyższy średni wynik netto i najmniejszą oczekiwaną stratę, jak stabilny jest proces uczenia oraz czy uzyskane strategie przewyższają przyjęte strategie bazowe. Agenci bazowi służą jako punkty odniesienia do oceny metod uczenia przez wzmacnianie.

1.4. Struktura pracy

Struktura pracy składa się z kilku rozdziałów. W rozdziale pierwszym przedstawiam cel, zakres oraz problem badawczy pracy. W rozdziale drugim zawieram podstawy teoretyczne dotyczące pokera, Texas Hold'em, Ultimate Texas Hold'em, wartości oczekiwanej, przewagi kasyna oraz uczenia przez wzmacnianie.

W kolejnych rozdziałach opisuję projekt środowiska symulacyjnego, sposób reprezentacji stanu gry, funkcję nagrody oraz zastosowane metody uczenia przez wzmacnianie. Następnie przedstawiam eksperymenty, uzyskane wyniki oraz analizę porównawczą agentów. Ostatni rozdział zawiera podsumowanie pracy, wnioski oraz możliwe kierunki dalszego rozwoju.

2. Podstawy teoretyczne

2.1. Poker jako gra z niepełną informacją

Poker jest zbiorem gier karcianych, w których wynik zależy zarówno od losowego rozdania kart, jak i od decyzji podejmowanych przez graczy. W przeciwieństwie do gier z pełną informacją (np. szachy) uczestnicy rozgrywki nie znają wszystkich elementów stanu gry. Ukryte pozostają przede wszystkim karty przeciwników, co sprawia, że decyzje podejmowane są w warunkach niepełnej informacji.

Właśnie z uwagi na tę niepełną informację uznałem pokera za ciekawy problem badawczy. W pokerze pojedyncza decyzja gracza nie powinna być oceniana wyłącznie na podstawie uzyskanego wyniku na koniec rozdania. Bardziej istotne jest, jak dana decyzja wpływa na wartość oczekiwaną (ang. *expected value*, EV) w dłuższym horyzoncie czasowym, przy wielu rozdaniach.

2.2. Texas Hold'em

Odmiana pokera Texas Hold'em jest jedną z najpopularniejszych na świecie. W tej odmianie każdy z graczy otrzymuje po dwie zakryte karty własne (ang. *hole cards*), znane tylko temu graczowi, natomiast na stole etapami pojawiają się karty wspólne (ang. *community cards*) - ostatecznie pięć kart wspólnych. Gracz, wykorzystując karty wspólne oraz swoje karty własne, musi utworzyć możliwie najlepszy układ pięciokartowy.

Sama rozgrywka składa się z kilku etapów: etapu przed flopem (ang. *preflop*), flopa (ang. *flop*), czyli odkrycia trzech pierwszych kart wspólnych, turna (ang. *turn*), czyli czwartej karty wspólnej, rivera (ang. *river*), czyli odkrycia piątej i ostatniej karty wspólnej, oraz showdownu (ang. *showdown*), czyli końcowego porównania układów. Warto dodać, że pomiędzy odkrywaniem kolejnych kart wspólnych dokonuje się palenia kart (ang. *burning*), czyli odkładania wierzchniej karty z talii na bok. Każdy z tych etapów poprzedza runda licytacji, w której gracze mogą stawiać zakłady, podbijać je lub spasować.

2.3. Ranking układów pokerowych

Zarówno w Texas Hold'em, jak i w Ultimate Texas Hold'em końcowy wynik rozdania zależy od siły najlepszego układu pięciokartowego utworzonego z dostępnych kart (pięciu kart wspólnych oraz dwóch własnych). Układy pokerowe mają ustaloną hierarchię, która pozwala jednoznacznie porównać ręce graczy lub krupiera w odmianie UTH. Przykładowy ranking układów od najsilniejszego do naj słabszego przedstawiam w tabeli 2.1 [1].

Najsilniejszym układem jest poker królewski, natomiast naj słabszym układem jest wysoka karta. Jeśli gracz i krupier posiadają układ tej samej kategorii (np. obaj mają parę), o zwycięstwie decydują wartości kart składających się na dany układ oraz karty

dodatkowe (ang. *kickers*).

Tabela 2.1. Ranking układów pokerowych od najsilniejszego do najslabszego

Układ	Opis
Poker królewski	A, K, Q, J, 10 w tym samym kolorze
Poker	Pięć kolejnych kart w tym samym kolorze
Kareta	Cztery karty tej samej wartości
Full	Trójka oraz para
Kolor	Pięć kart w tym samym kolorze
Strit	Pięć kolejnych kart
Trójka	Trzy karty tej samej wartości
Dwie pary	Dwa różne układy par
Para	Dwie karty tej samej wartości
Wysoka karta	Brak silniejszego układu

2.4. Ultimate Texas Hold'em

2.4.1. Charakterystyka gry

Ultimate Texas Hold'em jest kasynową odmianą pokera opartą na zasadach Texas Hold'em. Różnica polega na tym, że gracz rywalizuje z krupierem, który reprezentuje kasyno, a nie z innymi graczami, co oznacza, że konieczność blefowania (ang. *bluffing*) jest tu zbędna. Istotną cechą Ultimate Texas Hold'em jest również ograniczona liczba momentów decyzyjnych: gracz może wykonać zakład Play (ang. *Play bet*) tylko raz w trakcie rozdania, a im wcześniej podejmie tę decyzję, tym wyższy zakład może postawić, kosztem mniejszej liczby dostępnych informacji [1], [2]. Szczegółowe wysokości zakładu Play na poszczególnych etapach przedstawia tabela 2.2.

2.4.2. Przebieg rozdania

Rozdanie rozpoczyna się od postawienia przez gracza obowiązkowych zakładów Ante (ang. *Ante bet*) oraz Blind (ang. *Blind bet*). Oba te zakłady stawia się w tej samej wysokości. Opcjonalnie gracz może również postawić zakład poboczny (ang. *side bet*), na przykład Trips, który opisuję szerzej w dalszej części tego rozdziału [1].

Kiedy zakłady Blind oraz Ante zostaną postawione, krupier rozdaje graczowi i sobie po dwie karty własne - karty krupiera pozostają dla gracza zakryte. Teraz, w fazie preflop, po ujrzeniu swoich dwóch kart, gracz stoi przed pierwszą decyzją: może zaczekać (ang. *check*) lub wykonać zakład Play. Czekanie powoduje przejście do kolejnego etapu gry, jakim jest flop - następuje palenie jednej karty z talii i odkrycie kolejnych trzech kart wspólnych, a gracz znów podejmuje decyzję, czy chce czekać, czy wykonać zakład Play. Czekając również po flopie, następuje palenie karty i odkrywane są dwie ostatnie karty wspólne (turn i river), a gracz musi wybrać pomiędzy spasowaniem a wykonaniem zakładu Play. Wysokości zakładu Play na każdym z tych etapów przedstawiono w tabeli 2.2 [1], [2].

2.4.3. Zakłady i decyzje gracza

Zakłady Blind i Ante są obowiązkowe, natomiast zakład Play jest opcjonalny, zależny od decyzji gracza i możliwy do postawienia raz w trakcie rozdania. To właśnie zakład Play, z punktu widzenia modelowania problemu jako środowiska uczenia przez wzmocnianie, jest najważniejszy, ponieważ jego wysokość i moment wykonania wynikają z decyzji agenta. Ante i Blind traktuję jako początkowy koszt udziału w rozdaniu, natomiast zakład Play odzwierciedla wybór strategii w aktualnym stanie gry.

Tabela 2.2. Dostępne decyzje gracza w Ultimate Texas Hold'em

Etap	Dostępne decyzje	Wysokość zakładu Play
Preflop	czekanie lub zakład Play	3x albo 4x Ante
Flop	czekanie lub zakład Play	2x Ante
Po odkryciu całego stołu	spasowanie lub zakład Play	1x Ante

2.4.4. Rozstrzygnięcie rozdania

Po dokonaniu decyzji przez gracza o wykonaniu zakładu Play krupier odstawia swoje dwie karty własne. Gracz oraz krupier tworzą najlepszy możliwy układ pięciokartowy z siedmiu dostępnych kart. Następnie układy są porównywane zgodnie z hierarchią układów pokerowych.

Krupier kwalifikuje się do gry, jeżeli posiada co najmniej parę. Jeżeli krupier się nie kwalifikuje, zakład Ante jest zwracany graczowi. Zakład Play jest rozliczany na podstawie bezpośredniego porównania układu gracza i krupiera. W przypadku zwycięstwa gracza zakład Play wypłacany jest w stosunku 1:1, w przypadku przegranej gracz traci zakład Play, a w przypadku remisu zakład jest zwracany [1], [2].

Zakład Blind ma odrębną logikę rozliczania i nie jest wypłacany za każdy zwycięski układ gracza. Jeżeli gracz pokona krupiera układem o wartości co najmniej strita, Blind wypłacany jest zgodnie z tabelą wypłat przedstawioną w tabeli 2.3. Jeżeli gracz wygra rozdanie układem słabszym niż strit, zakład Blind jest zwracany. W przypadku przegranej gracza zakład Blind jest tracony, a w przypadku remisu zwracany [1].

Tabela 2.3. Tabela wypłat zakładu Blind przyjęta w modelu środowiska

Układ gracza	Wypłata
Poker królewski	500:1
Poker	50:1
Kareta	10:1
Full	3:1
Kolor	3:2
Strit	1:1
Pozostałe układy	Zwrot

2.4.5. Zakłady poboczne

W wielu wariantach Ultimate Texas Hold'em dostępne są również zakłady poboczne - są to Trips i Progressive. Zakład Trips jest opcjonalny i wypłacany na podstawie końcowego układu gracza, niezależnie od tego, czy gracz pokonał krupiera - najczęściej wygrywa wtedy, gdy końcowy układ gracza ma wartość co najmniej trójki. Zakłady poboczne mogą różnić się w zależności od kasyna i stosowanej tabeli wypłat [1].

Głównym celem pracy jest modelowanie sekwencyjnego procesu decyzyjnego dotyczącego zakładu Play. Ponieważ zakłady poboczne są opcjonalne, a wysokość ich wypłat zależy od konkretnego kasyna, zdecydowałem się ich nie uwzględniać w modelu środowiska.

2.5. Wartość oczekiwana i przewaga kasyna

Wartość oczekiwana (ang. *expected value*, EV) określa średni wynik finansowy decyzji lub strategii przy założeniu dużej liczby powtórzeń gry. W kontekście Ultimate Texas Hold'em pojedyncze rozdanie może zakończyć się zarówno zyskiem, jak i stratą, jednak skuteczność strategii należy oceniać na podstawie średniego wyniku uzyskiwanego w wielu rozdaniach.

Przewaga kasyna (ang. *house edge*) jest matematyczną miarą określającą oczekiwaną zysk kasyna względem zakładu gracza. Bynajmniej nie oznacza ona, że kasyno wygrywa każde pojedyncze rozdanie, lecz że przy dużej liczbie rozegranych rozdań średni wynik będzie przesunął się na korzyść kasyna. Oczywiście, gracz może osiągać krótkoterminowe zyski, jednak w długim okresie wynik gry powinien zbliżać się do wartości oczekiwanej wynikającej z zasad gry [3].

W Ultimate Texas Hold'em przewaga kasyna podawana jest względem początkowego zakładu Ante. Metryki, które przyjąłem, opierają się na wyniku netto względem Ante. Nawet niewielka procentowa przewaga kasyna prowadzi do istotnej oczekiwanej straty w długim horyzoncie czasowym.

W tabeli 2.4 przedstawiam przykładowe wartości przewagi kasyna dla wybranych gier kasynowych, w tym Ultimate Texas Hold'em [4].

Tabela 2.4. Przykładowe wartości przewagi kasyna dla wybranych gier kasynowych

Gra	Przewaga kasyna
Blackjack	0,28%
Ultimate Texas Hold'em	2,19%
Ruletka europejska	2,70%
Ruletka amerykańska	5,26%
Automaty do gier	2–15%

Tabela 2.4 pokazuje, że przewaga kasyna jest cechą konstrukcyjną gier hazardowych, ale jej poziom istotnie różni się pomiędzy grami, a podane wartości zależą przy tym od wariantu zasad gry. Chciałbym zaznaczyć, że celem niniejszej pracy nie jest

wykazanie, że agent może trwale uzyskać dodatnią wartość oczekiwaną w grze fundamentalnie zaprojektowanej na korzyść kasyna, lecz sprawdzenie, które metody uczenia przez wzmacnianie są w stanie nauczyć się strategii minimalizującej tę przewagę.

2.6. Strategie bazowe i ocena jakości strategii

Zdecydowałem się wprowadzić dwie strategie bazowe: agenta losowego (ang. *random agent*) i agenta regułowego (ang. *rule-based agent*). Te dwa agenty są dla mnie punktami odniesienia, pozwalającymi ocenić jakość strategii wyuczonej przez agenta uczącego się przez wzmacnianie. Ważne dla mnie jest porównanie agentów uczących się pomiędzy sobą, ale również względem strategii bazowych. Agent losowy wybiera jedną z legalnych akcji bez uwzględniania siły kart, stanowi prosty punkt odniesienia i umożliwia wstępną kontrolę działania infrastruktury eksperymentalnej. Agent regułowy wykorzystuje z góry określone heurystyki i reprezentuje bardziej wymagający punkt odniesienia.

Samo przewyższenie agenta losowego nie stanowi wystarczającego dowodu uzyskania jakościowej strategii, natomiast porównanie z agentem regułowym pozwoli mi ocenić, czy uczenie prowadzi do decyzji konkurencyjnych wobec jawnie zaprojektowanych zasad.

2.7. Uczenie przez wzmacnianie

Uczenie przez wzmacnianie (ang. *reinforcement learning*, RL) jest paradygmatem uczenia maszynowego, w którym agent uczy się podejmowania decyzji poprzez interakcję ze środowiskiem. W każdym kroku agent obserwuje aktualny stan (ang. *state*) środowiska, wybiera akcję (ang. *action*), a następnie otrzymuje nagrodę (ang. *reward*) oraz przechodzi do kolejnego stanu. Celem agenta jest wyuczenie strategii, określanej również jako polityka decyzyjna (ang. *policy*), która maksymalizuje sumę nagród w długim horyzoncie czasowym [5].

Przed flopem gracz zna jedynie swoje dwie karty, ale może wykonać najwyższy zakład Play. Po flopie posiada więcej informacji, lecz maksymalny zakład jest mniejszy. Po odkryciu wszystkich kart wspólnych zna już pełny board, ale może wykonać wyłącznie zakład 1x Ante albo spasować. Agent musi więc nauczyć się kompromisu pomiędzy ryzykiem, ilością informacji oraz potencjalną wypłatą.

2.7.1. Podstawowe pojęcia

Zachowanie agenta opisuje polityka, która może być deterministyczna, przypisując stanowi jedną akcję, albo stochastyczna, określając rozkład prawdopodobieństwa wyboru akcji. Jakość decyzji ocenia się na podstawie zwrotu epizodycznego, czyli sumy nagród uzyskanych do końca epizodu:

$$G_t = \sum_{k=0}^{T-t-1} \gamma^k r_{t+k}, \quad (2.1)$$

gdzie $\gamma \in [0, 1]$ jest współczynnikiem dyskontowania, a T oznacza koniec epizodu. Współczynnik γ reguluje wagę nagród odległych w czasie względem nagród natychmiastowych [5].

Oczekiwany zwrot z danego stanu opisuje funkcja wartości stanu $V^\pi(s)$, natomiast oczekiwany zwrot po wykonaniu akcji w danym stanie funkcja wartości akcji $Q^\pi(s, a)$. Te funkcje pozwalają porównywać decyzje i stanowią podstawę w wielu metodach uczenia [5].

W trakcie uczenia agent musi równoważyć eksplorację (ang. *exploration*), czyli wypróbowywanie nowych akcji w celu zdobycia informacji, oraz eksploatację (ang. *exploitation*), czyli wybór akcji uznanych dotąd za najlepsze. Niewłaściwy balans między nimi prowadzi do niestabilnego przebiegu uczenia.

Funkcje wartości i polityki można reprezentować w postaci tablicowej, gdy przestrzeń stanów jest niewielka, albo za pomocą aproksymacji funkcji, na przykład sieci neuronowej, gdy przestrzeń stanów jest duża. Przestrzeń stanów Ultimate Texas Hold'em jest zbyt duża na podejście tablicowe, dlatego funkcję wartości akcji aproksymuję siecią neuronową, co opisuję szczegółowo w rozdziale dotyczącym zastosowanej metody uczenia [5].

Dwa elementy konfiguracji procesu uczenia mają dla mnie nie bagatelne znaczenie, są to sposób reprezentacji obserwacji, decydujący o tym, jakie informacje trafiają na wejście agenta, oraz konstrukcja funkcji nagrody, przekształcająca finansowy wynik rozdania w sygnał uczący. To na analizie tych dwóch elementach skupiam się w niniejszej pracy.

2.8. Modelowanie UTH jako procesu decyzyjnego

Kończąc niniejszy rozdział, chciałbym podkreślić, że w Ultimate Texas Hold'em agent nie zna pełnego stanu środowiska, a jedynie jego obserwację. Agent nie wie, jakie karty ma krupier, ani jakie karty są następne w talii. Problem niniejszej pracy można więc traktować jako częściowo obserwowalny proces decyzyjny. To rozróżnienie obserwacji od pełnego stanu jest istotne dla zachowania niepełnej informacji, która jest charakterystyczna dla pokera. Odwzorowałem to w projekcie środowiska opisanym w kolejnym rozdziale [5].

Spis rysunków

Spis tabel

2.1	Ranking układów pokerowych od najsilniejszego do najslabszego	8
2.2	Dostępne decyzje gracza w Ultimate Texas Hold'em	9
2.3	Tabela wypłat zakładu Blind przyjęta w modelu środowiska	9
2.4	Przykładowe wartości przewagi kasyna dla wybranych gier kasynowych . .	10

Bibliografia

- [1] Tulalip Resort Casino, *Ultimate Texas Hold'em Game Rules*, https://www.everythingtulalip.com/wp-content/uploads/2024/04/ONEclub_0920_GameRules_RackCard_UltimateTexasHoldem-WEB.pdf, Dostęp: 2026-07-12.
- [2] W. of Odds, *Ultimate Texas Hold'em*, <https://wizardofodds.com/games/ultimate-texas-hold-em/>, Dostęp: 2026-07-07.
- [3] J. B. Maverick, *Understanding the House Edge: How Casinos Ensure Profit*, <https://www.investopedia.com/articles/personal-finance/110415/why-does-house-always-win-look-casino-profitability.asp>, Dostęp: 2026-07-12.
- [4] Wizard of Odds, *What is the House Edge?* <https://wizardofodds.com/gambling/house-edge/>, Dostęp: 2026-07-12.
- [5] R. S. Sutton i A. G. Barto, *Reinforcement Learning: An Introduction*, 2 wyd. Cambridge, Massachusetts: The MIT Press, 2018.